

Universidade Federal de Mato Grosso – UFMT
Campus Universitário de Várzea Grande
Faculdade de Engenharia
Engenharia de Computação

Carlos Daniel Santana Cunha

Luciano Tadeu Simões Simplicio Junior
Matheus Mesquita Yukishita

Relatório

Pathfinding e Otimização de Energia: Uma Abordagem Interativa com o Algoritmo A*

Várzea Grande
28 de outubro de 2026

Carlos Daniel Santana Cunha

Luciano Tadeu Simões Simplicio Junior
Matheus Mesquita Yukishita

Relatório
Pathfinding e Otimização de Energia: Uma Abordagem Interativa com o Algoritmo A*

Relatório elaborado como parte das atividades da disciplina de Inteligência Artificial, do curso de Bacharel em Engenharia de Computação, oferecida pela Faculdade de Engenharia.
Docente: Dr. Gustavo Post Sabin

Várzea Grande
28 de outubro de 2026

Lista de ilustrações

Figura 1 – *Grid* do Jogo 2
Figura 2 – Classe Estado em *GDScript* 4
Figura 3 – Função A* sem cálculo de estatísticas em *GDScript* 5
Figura 4 – Função Reconstruir Caminho em *GDScript* 6
Figura 5 – Comparação da energia acumulada pelo jogador e pelo A*. 7
Figura 6 – Reprodução simultânea dos percursos do jogador e do A*. 8

Lista de tabelas

Tabela 1 – Tabela de custos associados aos terrenos do ambiente virtual. 1
Tabela 2 – Comparação das heurísticas na primeira execução. 9
Tabela 3 – Comparação dos resultados obtidos em dez partidas. 9

Sumário

1 INTRODUÇÃO 1

2 METODOLOGIA 3
2.1 Representação do Problema 3
2.2 Definição 3
2.3 Aplicação da Heurística 4
2.4 A* (A-Estrela) 5

3 RESULTADOS 7
3.1 Comparação dos percursos 7
3.2 Reprodução dos percursos 8
3.3 Comparação entre heurísticas 8
3.4 Comparação entre partidas 9

4 CONCLUSÃO 11

REFERÊNCIAS 13

Capítulo 1

Introdução

O problema de busca de rotas otimizadas, amplamente conhecido na ciência da computação como *pathfinding*, representa uma das categorias mais clássicas e fundamentais dos problemas de otimização. Desde a roteirização de pacotes em redes de computadores até a navegação de veículos autônomos e a movimentação de personagens em jogos digitais (*NPCs*), a necessidade de deslocar um agente de um ponto de origem a um ponto de destino gastando a menor quantidade de recursos possível é um desafio constante e de alta relevância prática.

No escopo deste trabalho, o problema de otimização escolhido consiste na navegação espacial em um ambiente bidimensional (malha ou *grid*) onde o custo de deslocamento não é homogêneo. Diferentemente de cenários simplificados onde a distância métrica é o único fator limitante, o ambiente modelado apresenta diferentes tipos de superfícies e obstáculos, cada um impondo uma penalidade distinta ao deslocamento do agente, definida como "Custo de Energia". O objetivo central do problema é encontrar um caminho válido que conecte a origem ao destino minimizando o somatório total de energia gasta ao longo do trajeto.

Para ilustrar, analisar e testar a resolução matemática deste problema, foi desenvolvida uma aplicação interativa estruturada como um jogo de quebra-cabeça (*puzzle*) em 2D. A topologia do ambiente é composta por terrenos modulares, cujos pesos foram definidos da seguinte forma:

Tipo de Terreno	**Características**	**Custo de Energia**
Grama	Superfície plana e de fácil locomoção	1
Morro	Elevação que exige maior esforço físico	2
Água	Superfície densa e de movimentação lenta	3
Parede	Superfície intransponível	∞

Tabela 1 – Tabela de custos associados aos terrenos do ambiente virtual.

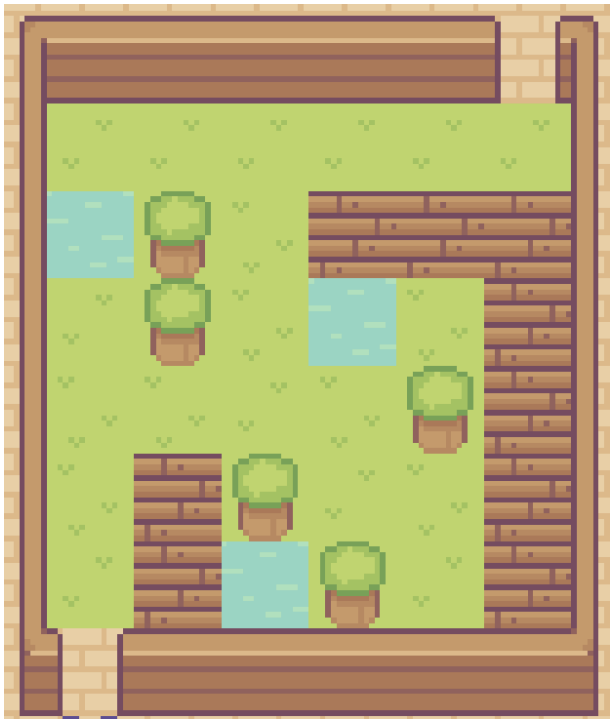


Figura 1 – *Grid* do Jogo

Fonte: Elaborado pelos autores (2026).

A principal contribuição e diferencial da modelagem proposta é a análise comparativa entre a intuição humana e a precisão algorítmica. Na aplicação desenvolvida, o usuário humano é desafiado a traçar, de forma manual e baseada em sua percepção visual, o caminho que julga consumir a menor quantidade de energia. Após a tentativa humana, o sistema computacional resolve o mesmo mapa utilizando o algoritmo heurístico A* (A-Estrela), revelando a rota matematicamente ótima (*gabarito*).

Essa abordagem interativa permite comparar a intuição do jogador contra a precisão matemática da máquina. Ao medir a diferença de custo entre a rota escolhida no 'olhômetro' pelo humano e o gabarito perfeito gerado pelo A*, o trabalho prova na prática por que algoritmos de busca são fundamentais para não desperdiçar recursos em problemas de otimização.

CAPÍTULO 2

Metodologia

A forma de implementação utilizada é o algoritmo de busca A* (A-Estrela), a forma de solução mais conhecida da busca de melhor escolha, que minimiza o custo total estimado da solução. As seções a seguir explicam as fórmulas do algoritmo, com base em Russell e Norvig (2013, seção 3.5.2).

2.1 Representação do Problema

O ambiente do jogo é uma grade, implementada como uma matriz bidimensional 6×6, com 36 células ou terrenos (malha ou *grid*), como na Figura 1. Cada célula da grade corresponde a um estado, que armazena a posição (x, y), com movimentação de célula em célula (acima, abaixo, esquerda e direita). O custo de cada passo é o "Custo de Energia" da célula em que o agente entra (Grama 1, Morro 2, Água 3), conforme a Tabela 1. A fórmula de somatório do "Custo de Energia" é

$$\sum_{i=0}^{k} c(v_i) \tag{1}$$

onde v_0 é a entrada, v_k é a saída e $c(v_i)$ é o custo de cada célula do caminho. A entrada é a célula $(0, 5)$, onde o A* começa, e a saída é a célula $(5, 0)$.

2.2 Definição

Foi implementado o estado do jogo para o núcleo do algoritmo A* (A-Estrela). Foram definidas as seguintes variáveis, como na Figura 2:

- **Pai / predecessor π:** guarda uma referência ao estado para reconstruir o caminho do estado de saída de volta até o estado de entrada;
- **$g(v)$:** é o custo real acumulado do estado de entrada até o estado v;

- **$h(v)$:** é a heurística para estimar a distância do estado v até o estado de saída, utilizando a distância de Manhattan;
- **$f(v)$:** é a prioridade do estado, o custo estimado da solução de menor gasto de energia que passa por v, dada pela fórmula:

$$f(v) = g(v) + h(v) \tag{2}$$

Figura 2 – Classe Estado em *GDScript*

```
class_name Estado

var posicao: Vector2i ## (x, y)
var pai: Estado ## predecessor π

var g := 0 ## custo do caminho g(v)
var h := 0 ## heurística h(v) ⇒ Manhattan

var f: int: ## prioridade (f(v) = g(v) + h(v))
    get():
        return g + h

func _init(p: Estado, pos: Vector2i) → void:
    pai = p
    posicao = pos

func vizinhos(matriz: Array) → Array[Vector2i]:
    var adj: Array[Vector2i] = [Vector2i(0, -1), Vector2i(0, 1), Vector2i(-1, 0), Vector2i(1, 0)]
    var res: Array[Vector2i] = []

    for direcao in adj:
        var nova_pos := posicao + direcao

        if (nova_pos.x ⩾ 0 and nova_pos.x < matriz[0].size()) \
        and (nova_pos.y ⩾ 0 and nova_pos.y < matriz.size()):
            res.append(nova_pos)

    return res

func manhattan(pos: Vector2i, obj: Vector2i) → int:
    return abs(obj.x - pos.x) + abs(obj.y - pos.y)
```

Fonte: Elaborado pelos autores (2026).

2.3 Aplicação da Heurística

A heurística escolhida é a distância de Manhattan no algoritmo A*, a soma das distâncias da posição até a saída. O movimento é proibido ao longo de diagonais, então a distância contada é a soma das horizontais e verticais:

$$h(v) = |x_s - x_v| + |y_s - y_v| \tag{3}$$

onde (x_v, y_v) é a posição do estado v e (x_s, y_s) é a posição do estado de saída. Essa heurística é otimista (RUSSELL; NORVIG, 2013, seção 3.6).

2.4 A* (A-Estrela)

O algoritmo foi adaptado, conforme a Figura 3, para que o custo inicial g do estado de entrada corresponda ao valor da célula de partida, conforme as regras do jogo:

Figura 3 – Função A* sem cálculo de estatísticas em *GDScript*

```
static func astar(matriz: Array, entrada := Vector2i(0, 5), saida := Vector2i(5, 0)) -> Estado:
    var Q := FilaPrioridade.new()
    var visitada := {}
    var g_values := {}

    var start := Estado.new(null, entrada)
    start.g = matriz[entrada.y][entrada.x]
    start.h = start.manhattan(entrada, saida)
    g_values[entrada] = start.g # Inicializar custo do estado entrada

    Q.enfileirar(start, start.f)

    while Q.contar > 0: # verifica se Q está vazia
        var v: Estado = Q.desenfileirar()

        if v.posicao in visitada:
            continue

        visitada[v.posicao] = true

        if v.posicao == saida:
            return v

        for u in v.vizinhos(matriz):
            var novo_g: int = g_values[v.posicao] + matriz[u.y][u.x] # Custo do novo caminho (g(n))

            if u not in g_values or novo_g < g_values[u]:
                g_values[u] = novo_g
                var filho := Estado.new(v, u)
                filho.g = novo_g
                filho.h = filho.manhattan(u, saida)
                Q.enfileirar(filho, filho.f)

    return null
```

Fonte: Elaborado pelos autores e adaptado do Laboratório 3 da disciplina (2026).

- ❑ **Fila de prioridade:** foi implementada a fila de prioridade, pois a linguagem GDScript (Godot) não possui uma estrutura pronta. Ela possui as funções enfileirar, que armazena o estado na posição certa pela prioridade $f(v)$, e desenfileirar, que retira o primeiro da fila, o de menor $f(v)$. Na busca A*, utiliza-se f em vez de g para ordenar a fila de prioridade (RUSSELL; NORVIG, 2013, seção 3.5).

- ❑ **Início:** o estado de entrada, com g igual ao custo da célula e h pela distância de Manhattan, entra na fila.

- ❑ **Repetição:** enquanto a fila não está vazia, retira o estado de menor f.

  - Se já foi visitado, descarta.
  - Se é a saída, termina.

- **Vizinhos:** para cada vizinho u, o novo custo é $g(v) + c(u)$. Se for menor que o custo já conhecido, guarda o novo custo e coloca u na fila.
- **Reconstruir caminho:** a função recebe o estado final e reconstrói o caminho pelo atributo pai (predecessor π) e guarda as posições num vetor. Um laço percorre os estados da saída até a entrada, e a função retorna o caminho invertido, conforme a Figura 4.

Figura 4 – Função Reconstruir Caminho em *GDScript*

```
static func reconstruir_caminho(estado_final: Estado) → Array[Vector2i]:
    var caminho: Array[Vector2i] = []
    var atual: Estado = estado_final

    while atual ≠ null:
        caminho.append(atual.posicao)
        atual = atual.pai

    caminho.reverse()
    return caminho
```

Fonte: Elaborado pelos autores (2026).

Capítulo 3

Resultados

3.1 Comparação dos percursos

A Figura 5 apresenta a comparação entre a evolução do consumo de energia do jogador e do algoritmo A*. A linha vermelha representa o jogador, enquanto a linha cinza representa o A*. O eixo horizontal indica os passos e o eixo vertical representa a energia acumulada.

Na execução apresentada, a curva do jogador termina acima da curva do A*, indicando um consumo acumulado maior. A representação gráfica permite observar como a diferença entre os consumos evolui durante os percursos.

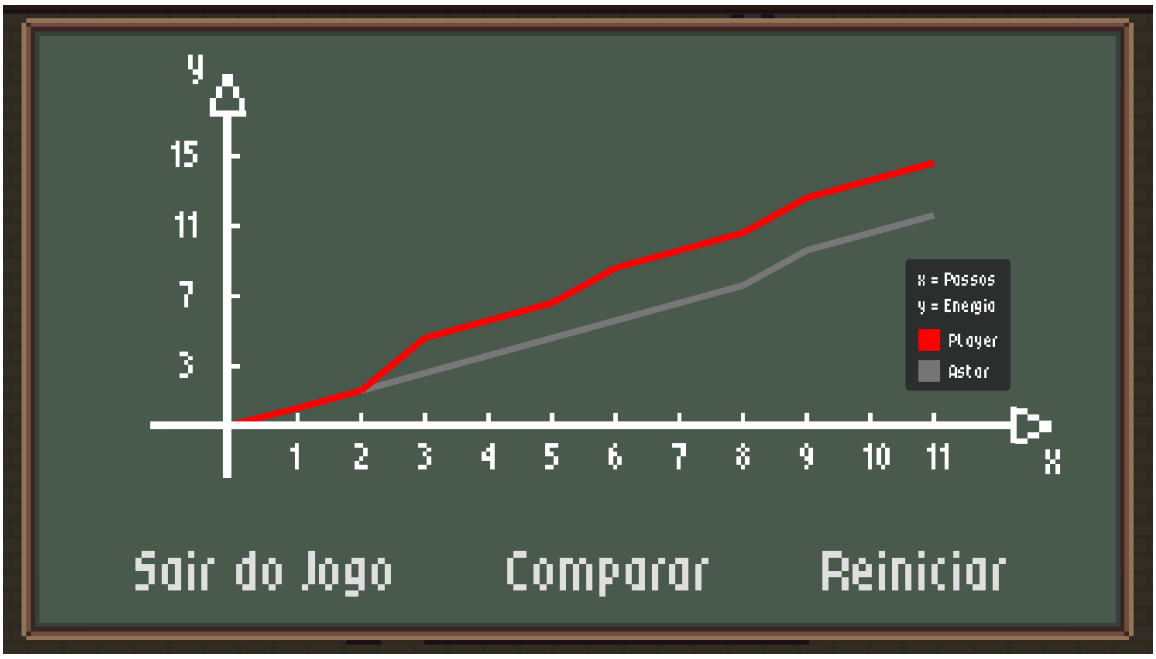


Figura 5 – Comparação da energia acumulada pelo jogador e pelo A*.

Fonte: Elaborado pelos autores (2026).

3.2 Reprodução dos percursos

Ao selecionar a opção *Comparar*, o sistema apresenta a reprodução simultânea dos dois percursos, conforme a Figura 6. O mapa à esquerda representa o trajeto do jogador, identificado pelo personagem de coelho, enquanto o mapa à direita apresenta o percurso do A*, representado pelo robô.

A reprodução permite acompanhar visualmente as trajetórias e observar os valores de energia exibidos durante a movimentação. Dessa forma, complementa o gráfico ao apresentar os percursos diretamente no mapa.

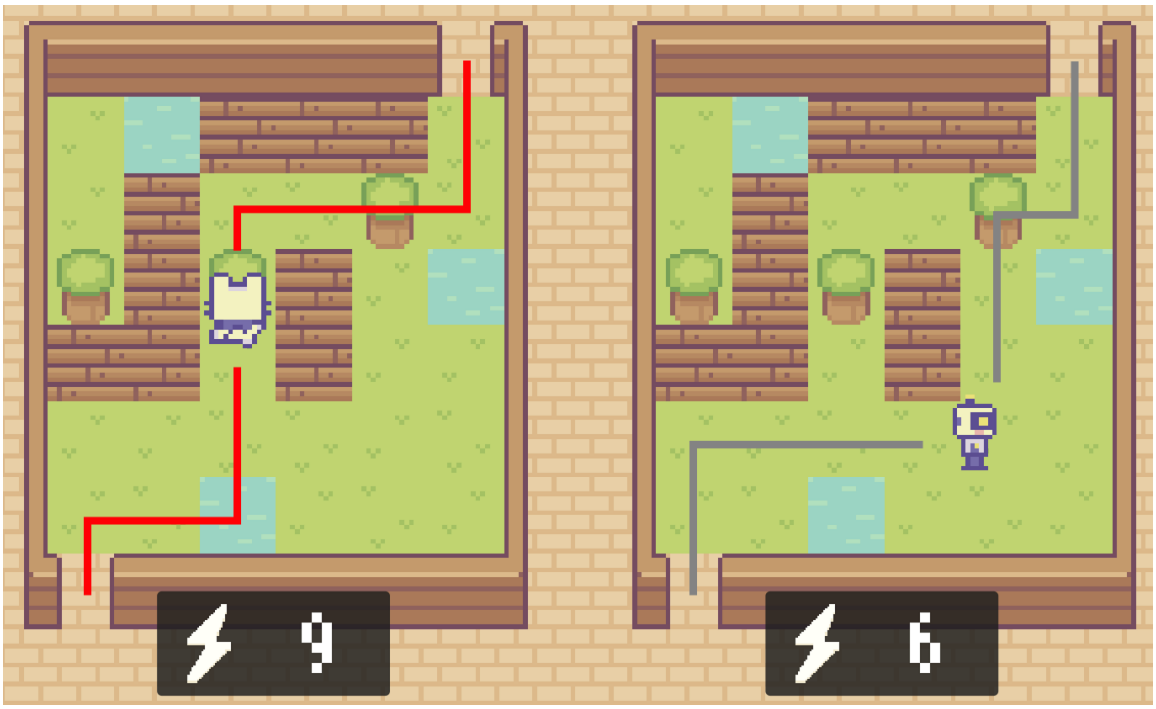


Figura 6 – Reprodução simultânea dos percursos do jogador e do A*.

Fonte: Elaborado pelos autores (2026).

3.3 Comparação entre heurísticas

Embora a análise principal utilize a heurística de Manhattan, também foram registrados resultados com as heurísticas Euclidiana e Chebyshev. A Tabela 2 apresenta os dados obtidos na primeira execução do sistema.

Na execução registrada, as três heurísticas encontraram caminhos com o mesmo tamanho e custo energético. Entretanto, houve diferenças na quantidade de estados enfileirados, expandidos e visitados. Manhattan apresentou o menor número de estados expandidos e visitados, com 18 em cada categoria. Chebyshev, por sua vez, apresentou o menor tempo registrado, enquanto Manhattan apresentou o maior.

Tabela 2 – Comparação das heurísticas na primeira execução.

Métrica	**Manhattan**	**Euclidiana**	**Chebyshev**
Enfileirados	34	33	32
Expandidos	18	20	21
Visitados	18	20	21
Tamanho do caminho	11	11	11
Custo energético	12	12	12
Tempo registrado	538	416	403

Fonte: Dados obtidos pelos autores na primeira execução (2026).

Esses resultados descrevem apenas a execução apresentada e não permitem concluir que uma heurística seja sempre mais rápida ou expanda menos estados. Para uma comparação mais abrangente, seria necessário realizar novas execuções em condições equivalentes. Como o foco deste trabalho é Manhattan, as demais heurísticas são apresentadas como referência complementar.

3.4 Comparação entre partidas

Para comparar o desempenho do jogador com o resultado de referência do A*, a Tabela 3 permite registrar a quantidade de passos e a energia final de ambos em dez partidas.

Tabela 3 – Comparação dos resultados obtidos em dez partidas.

Partida	**Jogador**		**A***	
	Passos	**Energia**	**Passos**	**Energia**
1	11	15	11	12
2	11	14	11	14
3	11	16	11	15
4	15	20	15	20
5	11	15	11	15
6	12	15	11	12
7	13	14	11	12
8	11	14	11	14
9	13	17	11	16
10	11	13	11	13

Fonte: Elaborado pelos autores (2026).

Os resultados mostram que o consumo energético do A* foi igual ou inferior ao do jogador nas dez partidas analisadas. Em cinco partidas, ambos apresentaram o mesmo consumo de energia; nas outras cinco, o A* obteve um custo menor. Não houve, nos registros apresentados, nenhuma partida em que o consumo do A* tenha sido superior ao do jogador.

Considerando o conjunto das dez partidas, o jogador acumulou 153 unidades de energia, enquanto o A* acumulou 143. A diferença foi de 10 unidades, equivalente a aproximadamente

6,5% do consumo total do jogador. Em média, o consumo foi de 15,3 unidades por partida para o jogador e de 14,3 para o A*.

Também foram observadas diferenças na quantidade de passos. Somando as dez execuções, o jogador realizou 119 passos, enquanto o A* realizou 114. O algoritmo utilizou menos passos em três partidas e a mesma quantidade nas outras sete. Esses resultados reforçam a importância de analisar conjuntamente as duas métricas, pois a quantidade de movimentos, isoladamente, não determina o consumo energético do percurso.

Na amostra analisada, portanto, o A* apresentou consumo energético igual ou inferior ao do jogador em todas as partidas. Embora esses dados indiquem uma vantagem do algoritmo nos registros obtidos, as conclusões se limitam às execuções realizadas e não devem ser generalizadas para situações que não foram avaliadas.

Capítulo 4

Conclusão

Este trabalho apresentou uma aplicação interativa em formato de quebra-cabeça 2D para estudar o problema de *pathfinding* com custo de energia não homogêneo. O ambiente foi modelado como uma grade 6×6 com terrenos de custos distintos (grama, morro, água e parede), e o algoritmo A* com a heurística de Manhattan foi implementado em GDScript para obter o percurso de menor gasto energético. Essa solução serviu de gabarito para a comparação com o caminho traçado pelo jogador.

A heurística de Manhattan é admissível neste cenário, pois o movimento é restrito às direções horizontal e vertical e o menor custo de entrada em uma célula é 1. Essa propriedade garante que o A* encontre um caminho de custo mínimo, o que justifica seu uso como referência.

Nas dez partidas analisadas, o A* obteve consumo de energia igual ou inferior ao do jogador em todas elas. Em cinco partidas os custos coincidiram e, nas outras cinco, o algoritmo gastou menos energia. No total, o jogador acumulou 153 unidades de energia contra 143 do A*, uma diferença de 10 unidades, ou cerca de 6,5% do consumo do jogador. Em relação aos passos, o jogador realizou 119 no total contra 114 do A*, sendo que o algoritmo usou menos passos em apenas três partidas. Os resultados também indicam que o menor número de passos não implica menor consumo, pois um trajeto curto pode atravessar terrenos de custo elevado. Isso reforça a necessidade de considerar a distância e o custo de cada terreno em conjunto, algo que a intuição visual do jogador nem sempre faz bem.

Na comparação entre heurísticas, Manhattan, Euclidiana e Chebyshev encontraram caminhos com o mesmo tamanho e o mesmo custo energético. Manhattan expandiu e visitou o menor número de estados, enquanto Chebyshev registrou o menor tempo. Como esses dados vêm de uma única execução, não permitem concluir que uma heurística seja superior às demais.

Entre as limitações do trabalho, destacam-se o tamanho reduzido da grade, a amostra de apenas dez partidas e a ausência de repetições controladas para a medição de tempo. Assim, as conclusões valem apenas para as execuções realizadas.

Como trabalhos futuros, sugere-se:

- ampliar a quantidade de partidas e de participantes;

- ❏ testar mapas maiores e com terrenos distribuídos de forma aleatória;
- ❏ repetir as medições de tempo em condições equivalentes para comparar as heurísticas de forma estatisticamente consistente;
- ❏ comparar o A* com outros algoritmos de busca, como Dijkstra e busca gulosa;
- ❏ incluir movimentos diagonais, o que exigiria revisar a escolha da heurística.

Em síntese, a aplicação cumpriu o objetivo de mostrar, de forma prática e visual, a vantagem de algoritmos de busca informada na minimização do gasto de recursos, além de servir como ferramenta didática para a disciplina de Inteligência Artificial.

Referências

RUSSELL, S.; NORVIG, P. **Inteligência artificial**. 3. ed. Rio de Janeiro: Elsevier, 2013. ISBN 978-8535237016.